게임 Starfield 리뷰어는 누가, 얼마나, 언제, 무엇에 실망하는가.

플레이 행동과 리뷰 텍스트로 본 평가

3 조 김민재 , 최용준

목차

1. 분석 개요
2. 데이터 소개
3. 품질 점검
4. 탐색적 데이터 분석
5. 리뷰 텍스트 기반 추천확률 산출
6. 유저 유형 도출 : K-Means 군집분석
7. 종합분석 : 페르소나 x 추천 확률
8. 불만 토픽 분석 : 무엇에 실망했나
9. 결론과 한계
10. 참고문헌

부록 . 데이터셋 미사용 열

분석 개요 - 1. 주제와 사전 조사

주제

· 평가가 갈리는 대작 게임 Starfield 에서 , 어떤 유형의 유저가 어떻게 평가하는가

왜 Starfield 인가

· 후보 게임들의 플레이타임 구간별 긍정률을 같은 API 로 수집해 비교 (2026-09-02 기준)

· RDR2 는 2 시간 이후 전 구간에서 긍정률 89~96% 로 사실상 상수

→ 어떤 모델을 붙여도 " 다들 좋아한다 " 는 결론밖에 나오지 않음

· Starfield 는 같은 축에서 17.9% → 67.7% 로 50%p 가까이 움직임

→ 설명해야 할 분산이 실제로 있는 게임

사전 조사

· 계획 단계에서 후보 4 개 게임의 리뷰를 같은 API 로 수집해 비교 (우측 표)

게임	리뷰 수	긍정률	판단
Starfield	175,210*	56%	선정 . 플레이타임 구간별 긍정률 17.9% → 67.7%
RDR2	913,006	92.5%	제외 . 2h 이후 89~96% 로 상수 , 부정 리뷰 7.5% 뿐
Cyberpunk 2077	977,133	86.9%	제외 . 출시 4 개월 80.3% → 최근 12 개월 94.9% 로 회복한 사례
Diablo IV	74,979	65.2%	제외 . 라이브서비스 ARPG 라 시즌마다 복귀 · 이탈 반복

* 계획 단계 수집 (2026-09-02) 기준 . 최종 수집 (09-08) 은 175,300 건 (6p) — 6 일 사이 추가된 리뷰

분석 개요 - 2. 선행연구

선행연구	무엇을 밝혔나	이 프로젝트에서의 쓰임
[1] Steam 리뷰 감성 → 이탈 예측 (SNAM, 2024)	SVM 감성 점수를 시계열에 넣어 이탈을 예측 (정확도 89%)	" 리뷰 감성 → 유저 행동 " 프레임의 근거 . 단 , 시계열 단위 → 본 분석은 개인 단위
[2] Steam 리뷰 길이와 감성 (Computers in Human Behavior, 2023)	리뷰 길이와 감성의 관계를 장르 단위로 분석	길이가 교란변수라는 근거 → 5 장에서 " 길이만 " 기준선을 세움
[3] Steam 리뷰 토픽 모델링 비교 (IEEE Trans. on Games, 2024)	Steam 리뷰 (No Man's Sky) 에서 임베딩 기반 방법이 LDA·NMF 보다 우수	같은 데이터 종류에서 임베딩 접근이 통한다는 도메인 근거
[4] MTEB 벤치마크 (EACL, 2023)	텍스트 임베딩 모델을 분류 · 군집 등 과제로 표준 평가	5 장 임베딩 모델 선정 기준 (다국어 리더보드)
[5] 임베딩의 길이 취약성 (EMNLP, 2023)	문장 임베딩에 길이 성분이 실재해 의미 비교를 왜곡	언어별 · 길이별 성능을 따로 점검한 이유 (5 장)
[6] BERTopic — 임베딩 군집 토픽 모델링 (arXiv, 2022)	문서 임베딩 → 군집 → 군집별 c-TF-IDF 로 토픽어를 뽑는 3 단계 구조	8 장 토픽 추출의 뼈대 . 군집은 K-Means, 특징어는 c-TF-IDF
[7] 다국어 표현의 언어 중립성 (Findings of EMNLP, 2020)	다국어 임베딩은 언어별로 뭉쳐 있어 언어별 평균을 빼면 중립성이 올라감	8 장에서 군집화 전 언어 성분을 제거한 방법의 근거

본 프로젝트의 위치

· 선행연구는 시계열 · 장르 · 게임 단위 , 대부분 영어 단일 언어 → 본 분석은 리뷰어 개인 단위 , 29 개 언어 전량을 다국어 임베딩으로 통합

· 유저 유형 (플레이 행동) 과 리뷰 텍스트 점수를 결합하고 , 그 위에 불만 토픽을 올려 " 어떤 유형이 어떻게 · 무엇에 실망하는가 " 를 묻는 접근은 확인한 범위에서 찾지 못함 (출처는 10 장 참고문헌)

분석 개요 - 3. 핵심 질문과 분석 흐름

핵심 질문

Q1. 리뷰 텍스트만으로 추천 / 비추천을 얼마나 정확히 예측할 수 있는가 ? → 5 장

Q2. 플레이 행동 (보유 게임 수 · 리뷰 수 · 플레이시간 · 업적) 으로
Starfield 리뷰어를 어떤 유형으로 나눌 수 있는가 ? → 6 장

Q3. 유저 유형에 따라 평가 (추천 여부 · 추천확률) 가 어떻게 다른가 ? → 7 장

Q4. 유형과 진행 단계에 따라 " 무엇에 " 실망하는가 ? → 8 장

가설

· H1. 게임 경험이 많은 유형 (보유 게임 · 작성 리뷰 多) 일수록 비판적일 것이다

· H2. 플레이시간이 짧은 시점에 쓴 리뷰일수록 부정적일 것이다

분석 대상

· Steam 리뷰 API + 업적 API 로 수집한 Starfield 리뷰어 72,271 명 → 정제 후 70,915 명

단계	입력	방법	산출
① **평가 점수**	리뷰 텍스트	다국어 임베딩 + 로지스틱 회귀	추천확률 0~1 (5 장)
② **유저 유형**	플레이 변수 4 개	K-Means 군집	페르소나 3 개 (6 장)
③ **결합**	① × ②	유형별 비교 (groupby)	누가 · 얼마나 · 언제 실망했나 (7 장)
④ **불만 토픽**	텍스트 부정 리뷰 (추천확률 < 0.3)	언어 · 길이 보정 → K-Means → c-TF-IDF	토픽 10 개 × 유형 · 단계 (8 장)

③ 이 이 분석의 결론이고 , ④ 는 ③이 보여준 차이의 " 이유 " 를 채운다 . ① 과 ②는 서로 독립적으로 만들어 7 장에서 처음 결합한다 .

데이터셋 소개 - 72,271 행 x 36 열

· 수집 2 단계 : ① 리뷰 API(appreviews) → 리뷰 전체 175,300 건 (09-08 기준) ② 각 steamid 의 업적 API → 프로필 · 업적 공개 유저 72,271 명 (41%) 만 조회 가능 → 분석 대상
· 비공개 유저가 빠지는 표본 편향 가능성은 한계에 기록 . 36 열 중 ◯ 표시한 10 개 변수 + 업적 파생 3 개를 분석에 사용
· 리뷰 반응 (투표 · 댓글 · 개발사 답변 7 개) 과 구매 · 플랫폼 플래그 (5 개) 12 개 열은 분석에 쓰지 않음 → 부록 41~42p

1. 리뷰 관련 컬럼

열 이름	타입	내용	값 범위 · 주의	사용
voted_up	bool	추천 / 비추천	긍정률 약 57%	◯
recommendationid	int	리뷰 고유 ID	전부 고유 . steamid 와 1: 1	–
language	str	리뷰어의 Steam 클라이언트 언어 설정 *	29 종	◯
review	str	리뷰 본문	192 건 NaN. 최장 8,000 자	◯
ts_created	int	리뷰 최초 작성 시각	2023-09-06 ~ 2026-09-07 (출시 당일부터 , 출시 전 리뷰 0 건)	◯
ts_updated	int	리뷰 마지막 수정 시각	미수정시 위 컬럼과 동일	–
app_release_date	int	게임 출시일	전부 2023-09-06 (상수)	–
written_during_early_access	bool	얼리엑서스 중 작성	전부 False	–

데이터셋 소개

2. 작성자 프로필

열 이름	타입	내용	값 범위 · 주의	사용
steamid	int	전부 고유 =1 인 1 리뷰	모든 파일의 병합 키	○
personaname	str	닉네임		–
profile_url	str	프로필 URL		–
avatar	str	아바타 해시		–
persona_status	str	수집 시점 접속 상태	offline 78%	–
games_owned	int	보유 게임 수	중앙값 235, 최대 36,496.	○
num_reviews	int	작성한 리뷰 총 수	최소 1, 중앙값 14, 최대 25,829	○

데이터셋 소개

3. 플레이타임 (단위 : 분)

열 이름	타입	내용	값 범위 · 주의	사용
playtime_at_review_min	int	리뷰 시점까지 누적 플레이타임	최소 5, 중앙값 2,258 분 (38h), 최대 503,105	○
playtime_forever_min	int	수집 시점 까지 누적 플레이타임	중앙값 4,628 분 (77h), 최대 1,016,252 분	○
playtime_2w_min	int	수집 시점 기준 최근 2 주 플레이	96.3% 가 0 - 2023 년 리뷰어에겐 무의미	–
last_played	int	마지막 플레이 시각	2023-09 ~ 2026-09	○

- 하드웨어 변수 (system_ram, os, cpu_name 등) 는 2025 년경 Steam 이 추가한 항목이라 결측 98.5% → 사용하지 않음
- 결측이 과하거나 분석 의미가 없는 변수를 빼고 10 개 선정
- 선정 변수 : steamid, language, review, ts_created, voted_up, games_owned, num_reviews, playtime_at_review_min, playtime_forever_min, last_played

데이터셋 소개

4. 업적 데이터

- 해당 데이터는 유저가 획득한 업적들의 이름과 각 업적별 획득 시각이 적혀있다 . 이대로 사용하기에는 어렵기 때문에 파생변수로 만들었다 .

열 이름	타입	내용	값 범위 · 주의	사용
stage_at_review	int	리뷰 시점의 메인 퀘스트 단계	stage(0~10)*. 2 단계에 42.8% 집중	○
n_ach_at_review	int	리뷰 시점 전체 업적 수	중앙값 10. 0 인 2,526 건 중 999 건은 미추적 , 1,527 건은 리뷰 전엔 업적이 없던 초반 리뷰어	○
n_ach_total	int	수집 시점 전체 업적 수	중앙값 23, 최대 82 (= 총 업적 수 **). 0 인 999 건 = 조기 이탈 또는 업적 비활성화 (10p)	○
stage_final	int	수집 시점 최종 퀘스트 단계	stage(0~10). 10 단계에 39.8%, 2 단계에 26.6%	–

* stage: 메인 퀘스트 업적 10 개를 진행 순서로 번호 매김 (1 For All, Into the Starfield … 8 Entangled → 9 Unearthed → 10 One Giant Leap), 리뷰 시점까지 해금한 것 중 가장 뒤 단계 . 8·9 순서는 실측 (둘 다 해금한 31,119 명 중 26,982 명이 Entangled 먼저) 으로 확정
** n_ach 최댓값 82 = Starfield 총 업적 수 (본편 +DLC) 와 일치 . 403 명이 정확히 82 개 → 수집 오류 아님

데이터 품질 점검

1. 분석 대상 제외

- 4 개 기준 중 하나라도 해당하면 제외
- 1,356 건 (1.9%) 제외 → 최종 70,915 건

제외 기준	건수	이유
업적 미추적 (n_ach_total = 0)	999	업적 비활성화 + 조기 이탈 혼재 *
라이브러리 비공개 (games_owned = 0)	167	보유자라 0 은 불가
리뷰 텍스트 없음	192	임베딩 대상 없음
플레이타임 오류	2	리뷰 시점 > 총
합계 (중복 제외)	1,356	→ 70,915 건 (98.1%)

2. 이상치

① 논리적 이상치 제거 : 리뷰 시점 > 총 플레이 (2 건)

② 상한값 대체 (윈저라이징): 상위 0.5% 는 봇 · 방치 계정의 극단값

→ 변수마다 상위 0.5%(355 건) 를 그 지점 값으로 바꿈 (제거 아님)

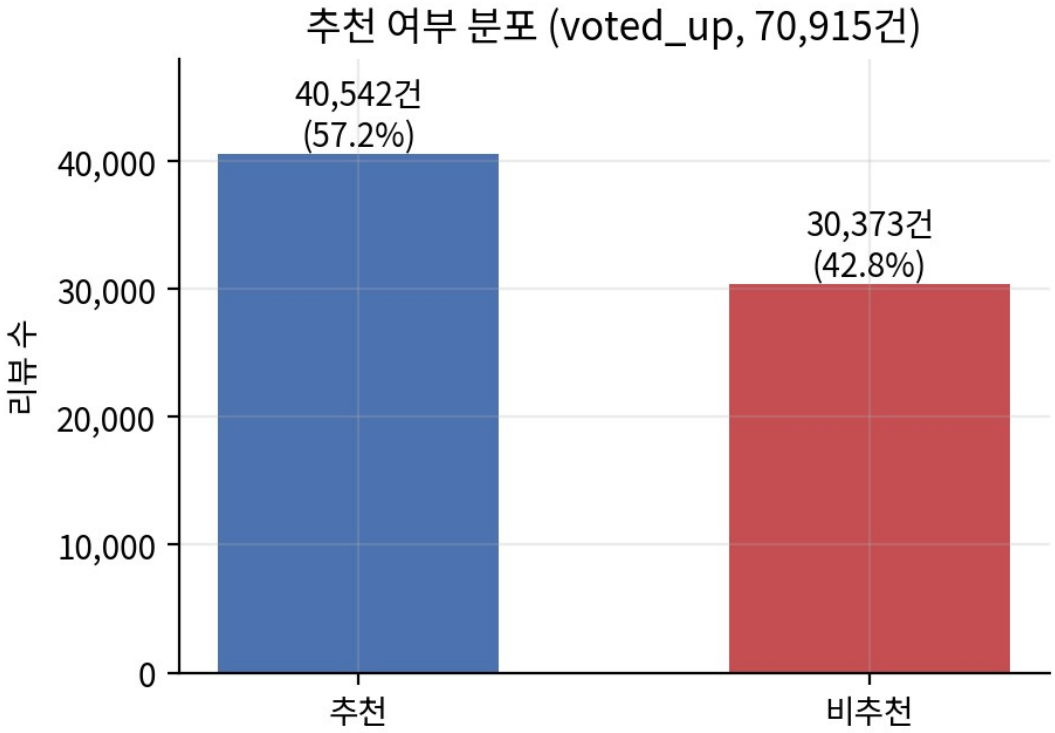
6 장 군집과 7 장 플레이시간 분석 모두 같은 값 사용

n_ach_at_review 는 상한 82 = 완주라 대체 안 함

열 이름	최솟값	최댓값	대체값 (상한)
games_owned	1.00	36,496.00	3,466.72
num_reviews	1.00	25,829.00	281.43
playtime_at_review_min	5.00	503,105.00	38,822.02
playtime_forever_min	6.00	1,016,252.00	85,909.87

* 업적 0 개 999 명은 두 집단 : 총 플레이 5 시간 미만 458 명 (첫 업적 전에 그만둔 조기 이탈 추정 , 긍정률 23%) + 5 시간 이상 541 명 (정상 플레이에서 5 시간 후 업적 0 개는 1% 미만 → 모드 · 콘솔로 업적이 꺼진 상태로 추정 , 그중 100 시간 이상 153 명). 후자는 진행 단계를 알 수 없고 전자는 수가 적어 함께 제외 . 가장 부정적인 초기 이탈자가 빠지는 영향은 한계 (39p) 에 기록 .

탐색적 데이터 분석 - 1. 명목형 종속변수 단변량 분석



불균형이 크지 않은 분포

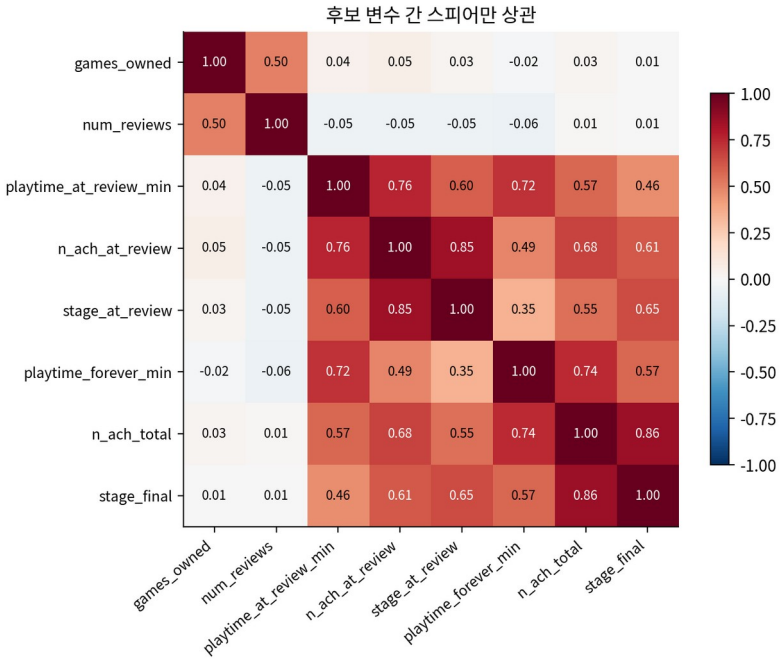
추천 40,542 건 (57.2%)
비추천 30,373 건 (42.8%)

탐색적 데이터 분석 - 2. 군집분석에 사용할 변수의 기술통계량 (상한값 대체 후 , 70,915 건)

	games_owned	num_reviews	playtime_at_review_min	n_ach_at_review
min	1.00	1.00	5.00	0.00
max	3,466.72	281.43	38,822.02 (647h)	82.00
mean	376.67	26.94	3,804.02 (63h)	14.67
50%	237.00	14.00	2,286.00 (38h)	10.00
std	456.78	38.22	5,087.64	12.89
skew	3.54	3.55	3.59	1.07
kurt	16.53	16.26	17.21	0.54
해석	분산이 큼 평균 > 중앙값 차이 큼 왜도 , 첨도 높음	분산이 큼 평균 > 중앙값 차이 큼 왜도 , 첨도 높음	분산이 큼 평균 > 중앙값 차이 큼 왜도 , 첨도 높음	왜도 · 첨도 낮음 (약간 치우침). 최솟값 0
판단	오른꼬리 형태 로그변환 필요	오른꼬리 형태 로그변환 필요	오른꼬리 형태 로그변환 필요	척도 통일을 위해 로그변환 (log1p) 선택

탐색적 데이터 분석 - 3. 군집 변수 선정을 위한 상관 확인

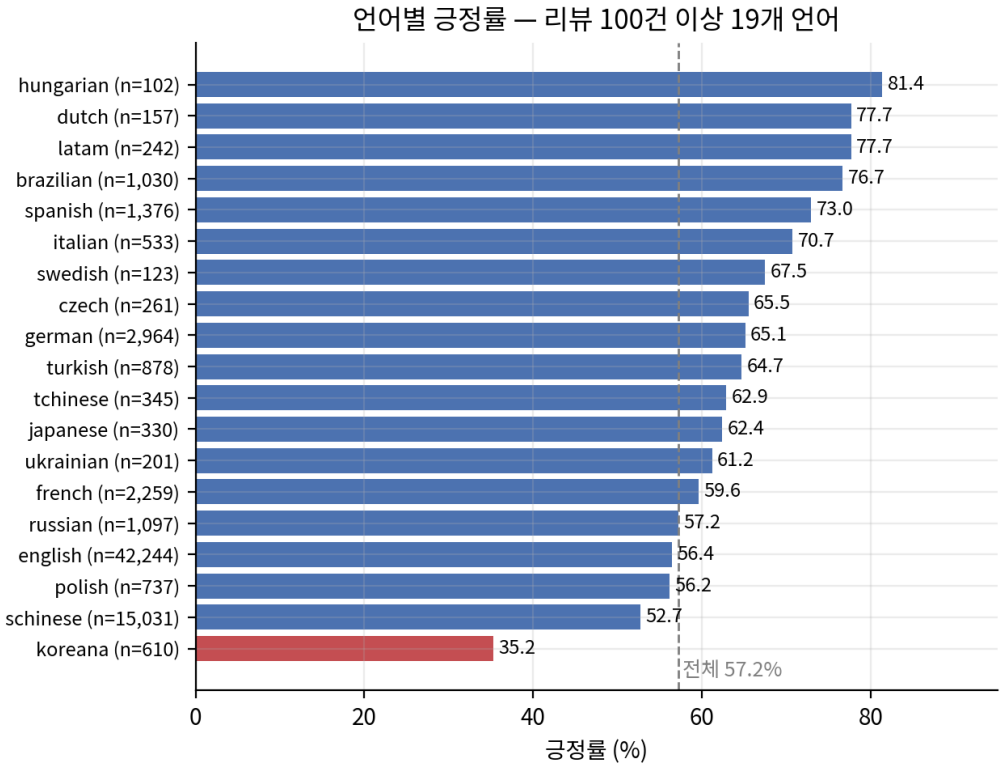
- 상관 0.8 이상 쌍은 하나만 : stage_at_review(0.847) 대신 n_ach_at_review(값 범위 0~82 로 정보량 많음)
- 리뷰 이후 변하는 " 최종 " 변수 (stage_final 등) 는 제외 → 군집 변수 4 개 확정 . VIF 는 참고용 (모두 10 미만)



변수	VIF
n_ach_at_review	6.48
n_ach_total	5.53
stage_at_review	5.23
stage_final	4.55
playtime_at_review_min	2.74
playtime_forever_min	2.53
num_reviews	1.22
games_owned	1.21

VIF: 후보 8 개 변수 전체 기준 (참고용 , 모두 10 미만)

탐색적 데이터 분석 - 4. 언어별 긍정비율 확인



- 리뷰 100 건 이상인 19 개 언어 중 한국어가 긍정률 35.2%(n=610) 로 최저 . 영어 56.4%(42,244) · 중국어 52.7%(15,031) · 독일어 65.1%(2,964) · 스페인어 73.0%(1,376)
- 언어에 따라 긍정률이 35~81% 까지 다르다 → 한 언어만 쓰면 표본이 편향된다 . 5 장에서 다국어 모델을 쓰는 근거
- language 는 Steam 클라이언트 설정값 (실제 글의 언어와 다를 수 있음)

리뷰 텍스트 기반 추천확률 산출

리뷰의 감성은 추천 / 비추천 버튼 하나로는 다 담기지 않는다 . 추천을 누르고도 불만을 길게 쓴 리뷰가 있기 때문이다 .

유저 유형 (6 장) 별로 평가를 비교하려면 리뷰마다 연속적인 평가 점수가 필요하다 . 그래서 먼저 리뷰 텍스트에서 " 추천확률 " 이라는 연속 점수를 뽑고 , 이 점수가 믿을 만한지 확인한다 .

이 모델은 감성을 재는 것이 아니라 리뷰 텍스트로 추천 여부 (voted_up) 를 맞히는 분류기다 . 그 예측확률을 뒤의 모든 분석에서 평가를 재는 잣대로 쓴다 .

리뷰 텍스트 기반 추천확률 산출 - 1. 접근 방법

왜 다국어 임베딩인가

· 리뷰 70,915 건이 29 개 언어 (영어 59.6% · 중국어 21.2% · 기타 19.2%)

· 영어만 쓰면 40% 를 버리고 , 버려지는 쪽의 긍정률이 다름
(중국어 53% · 독일어 65% · 한국어 35%) → 표본 편향

· 언어별 형태소 분석 대신 다국어 임베딩 모델 하나로 통일 , 원문 그대로 입력

모델

· multilingual-e5-large (1,024 차원) — MTEB 다국어 리더보드 기준 선정 ,
상위 모델 Qwen3-Embedding-0.6B 와 실측 비교 후 확정

· e5 권장대로 입력 앞에 "query: " 접두어를 붙여 임베딩

· 임베딩 → 로지스틱 회귀로 추천 / 비추천 예측 → 예측확률을 " 추천확률 " 로 사용

· 로지스틱 회귀 설정 : L2 규제 C=1(기본), class_weight 없음 (확률 보정 유지),
lbfgs, max_iter=300, 시드 3217 고정

단계	내용
① **입력**	리뷰 원문 (전처리 없음)
② **임베딩**	multilingual-e5-large (Colab GPU, 1,024 차원)
③ **분류**	로지스틱 회귀 (L2, C=1) → 추천 여부
④ **산출**	추천확률 (0~1)

리뷰 텍스트 기반 추천확률 산출 - 2. 분류 성능 (voted_up 예측)

모델	평가 방식	AUC	정확도
리뷰 길이만 (기준선)	holdout 20%	0.5740	0.5803
multilingual-e5-large	holdout 20%	0.9537	0.8866
Qwen3-Embedding-0.6B (비교)	holdout 20%	0.9530	0.8837
e5, 중복 텍스트 격리 분할 *	holdout 20% (그룹)	0.9497	0.8832
e5, 5-fold out-of-fold	전체 70,915 건	0.9541	0.8869

· 길이 기준선 대비 AUC +0.38 → 길이가 아니라 내용을 읽음

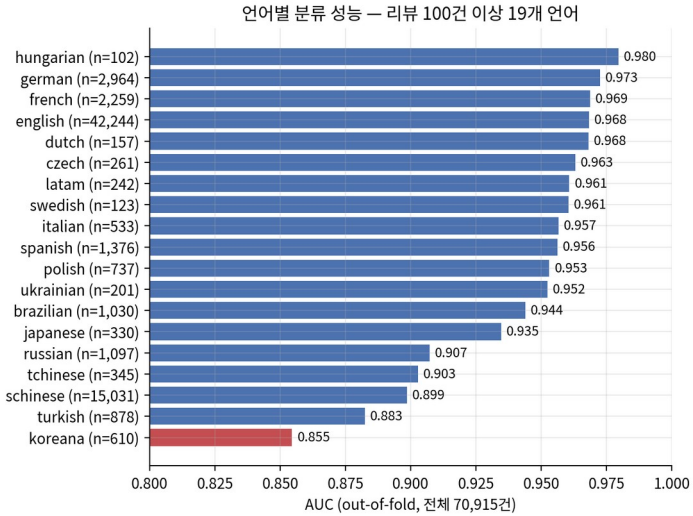
· 리더보드 상위 Qwen3 보다 이 데이터에서는 e5 가 근소 우위

· OOF 비추천 재현율 0.858 · 정밀도 0.876 (추천 0.909 · 0.895)

→ 비추천 7 건 중 1 건은 추천으로 잘못 읽음

· 언어별 AUC 0.86~0.98 (리뷰 100 건 이상 19 개 언어 , OOF 기준). 50 자 이상만 봐도 격차 유지

→ 길이가 아닌 모델의 언어별 표현력 차이 (한계). holdout 과 OOF 가 넷째 자리에서만 다름



* 중복 텍스트 격리 : "good", "10/10" 같은 똑같은 리뷰가 학습 · 평가 양쪽에 들어가면 점수가 부풀려지므로 , 같은 텍스트 (4,706 건) 는 한쪽에만 두도록 나눔

· 유저 유형별 (6 장) AUC 0.948~0.963 → 세 유형 모두 0.9 이상 , 모델이 유형에 공평 (7 장의 전제)

리뷰 텍스트 기반 추천확률 산출 - 3. 추천확률 산출과 보정

추천확률 = P(추천 | 리뷰 텍스트)

· 1 에 가까울수록 텍스트가 추천에 가깝다

· 전체 리뷰에 5-fold out-of-fold 로 부여 (중복 텍스트는 같은 fold 에 격리)

— 모든 리뷰가 자기를 학습하지 않은 모델로 채점됨

(holdout 모델을 전체에 적용하면 학습 행 80% 가 과신 방향으로 치우침)

보정 확인

· 예측확률 구간별 실제 추천 비율이 예측값과 거의 일치

· → 확률값을 그대로 연속 점수로 사용 가능

7 장에서 쓰는 구간 (경계 통일)

· 부정 0.3 미만 24,434 건 / 중간 0.3 이상 0.7 미만 11,106 건 (15.7%) / 긍정 0.7 이상 35,375 건

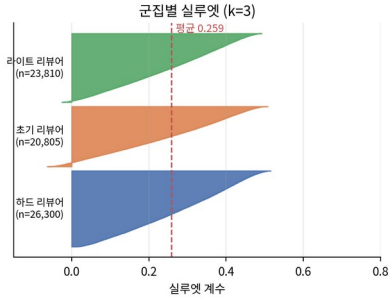
추천확률 구간	리뷰 수	실제 추천 비율	평균 예측
0.0 ~ 0.1	15,577	2.8%	0.036
0.1 ~ 0.3	8,857	15.1%	0.184
0.3 ~ 0.5	5,311	36.2%	0.397
0.5 ~ 0.7	5,795	60.0%	0.609
0.7 ~ 0.9	10,167	85.1%	0.817
0.9 ~ 1.0	25,208	98.1%	0.968

유저 유형 도출 : K-Means 군집분석 - 1. 개요

- 유저들을 특성에 따라 집단으로 나누어 비교 , 분석하기 위하여 군집화를 시도
- K-Means 선정 이유 : 1. 연속형 변수 처리에 적합 : 투입 변수가 모두 연속형
  2. 계산 속도가 빠름 : 약 7 만 건의 표본 처리에 적합
- 유저 특성을 나타낼 수 있는 변수들을 선정 : 1. 유저의 게임 경험 (보유 게임 수 , 작성 리뷰 수)
  2. 해당 게임 몰입도 (리뷰시점 플레이 시간 , 리뷰 시점 총 업적 수)
  - 상관이 높은 변수의 중복 배제 , 시간의 선후를 고려해 리뷰 이후 변수 제외
- 기술통계량 분석 결과 (12p) 에 따라 각 변수에 로그변환 적용
- 변수간 규모차이를 줄이기 위해 스케일링 (StandardScaler) 적용
- 군집화 결과는 페르소나로 정리해 다음 단원에서 추천확률 산출 결과와 연결하여 분석

K-Means 군집분석 - 2. 최적의 군집 수 (k) 찾기

k	스코어	전체면적	두께비	최소상대면적	균형지수
2	0.279	19,789.9	1.463	0.684	0.130
3	0.259	18,349.4	1.264	0.826	0.169
4	0.230	16,345.4	1.753	0.724	0.095
5	0.214	15,188.5	2.007	0.642	0.068
6	0.215	15,226.0	1.913	0.685	0.077
7	0.203	14,396.8	2.126	0.645	0.062
8	0.202	14,357.2	1.724	0.681	0.080
9	0.193	13,675.8	2.156	0.650	0.058
10	0.191	13,518.8	2.150	0.671	0.059



- 균형지수 = 스코어 x 최소상대면적 / 두께비

실루엣 스코어 (클수록 좋음)

두께비 (1 에 가까울수록 좋음)

최소상대면적 (1 에 가까울수록 좋음)

- 군집 수 k=2 : 플레이시간이 많은 그룹과 적은 그룹으로만 분리되어 유저의 게임 경험 관련 변수의 변별력이 없어짐

- 최적 군집 수 k = 3

- 주의점 : 실루엣 스코어 = 0.259 로 비교적 낮음

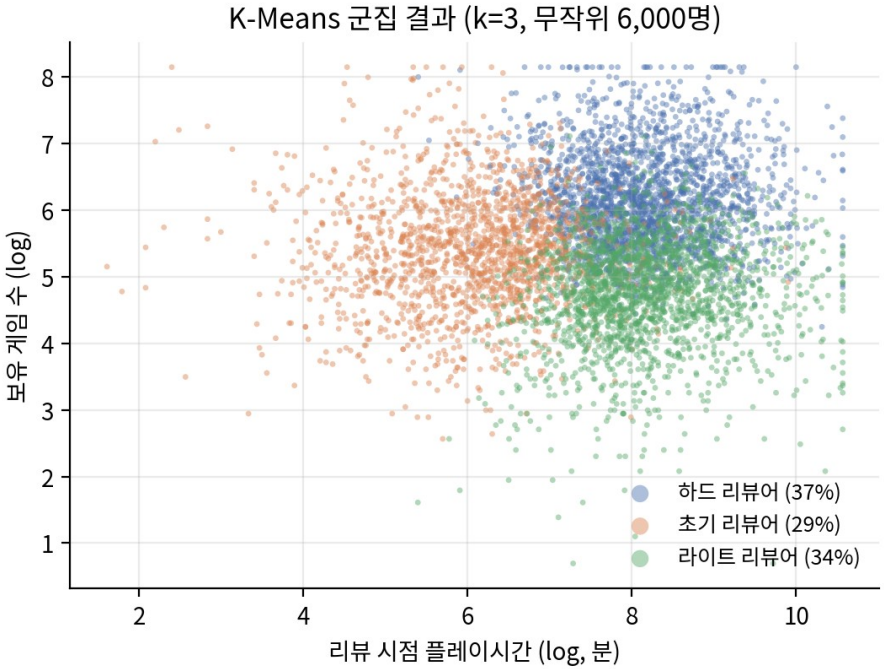
-> 경계가 명확하지 않아 군집 간 겹치는 부분이 존재

K-Means 군집분석 - 3. 페르소나 분석

- K-Means 군집 후 집단의 특성을 분석하여 페르소나 도출
- 정규성 검정 결과 , 모두 정규분포를 따르지 않아 중앙값을 사용하여 비교
- 리뷰 이후 플레이시간 = 총 플레이시간 - 리뷰 시점 플레이시간 (두 변수 모두 10p 의 상한값 대체 후 값)

군집	이름	인원 (%)	보유 게임 수	작성 리뷰 수	리뷰 시점 플레이시간 (h)	리뷰 시점 업적 수	리뷰 이후 플레이시간 (h)	긍정률
0	하드 리뷰어	26,300 (37.1%)	431	29	55.62	17	20.30	0.574
1	초기 리뷰어	20,805 (29.3%)	220	16	8.18	3	9.68	0.478
2	라이트 리뷰어	23,810 (33.6%)	124	5	53.93	16	28.86	0.650
전체		70,915 (100%)	237	14	38.1	10	19.72	0.572

K-Means 군집분석 - 4. 군집화 결과 (페르소나)



군집 0 (하드 리뷰어)
보유 게임 수와 작성 리뷰 수 ,
플레이시간이 모두 많음

군집 1 (초기 리뷰어)
리뷰 시점 플레이시간과 업적 수가
상대적으로 적음

군집 2 (라이트 리뷰어)
보유 게임 수와 작성 리뷰수는 적지만
플레이시간이 많음

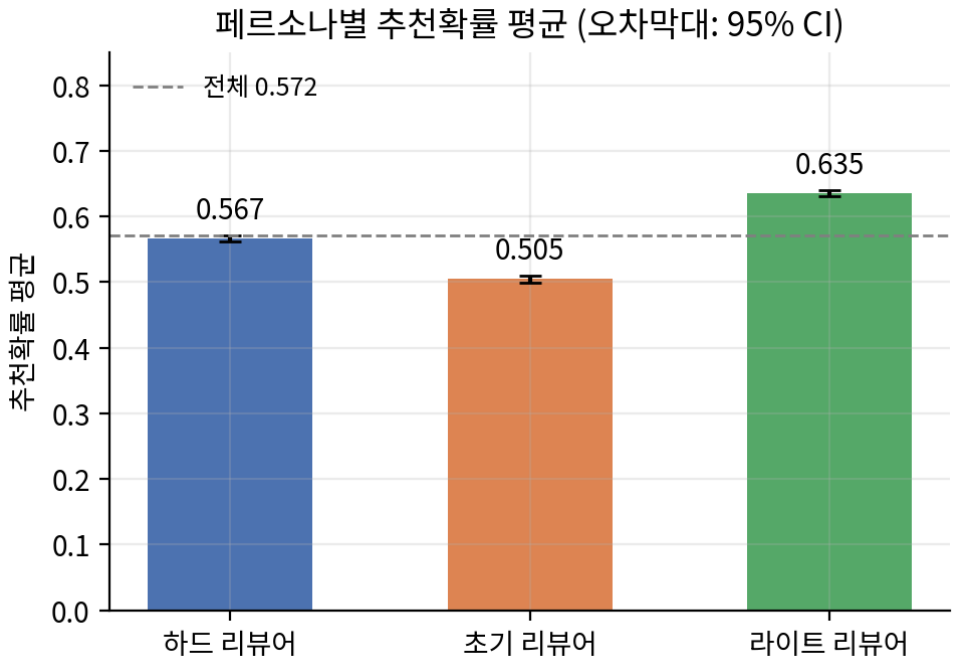
종합분석 : 페르소나 x 추천확률

5 장의 추천확률 (리뷰 한 건의 평가 점수) 과 6 장의 페르소나 (플레이 행동으로 나눈 세 유형) 는 서로 독립적으로 만들었다 . 이 장에서 둘을 처음 결합한다 .

질문은 넷이다 . 누가 더 불만족했나 (7-1·7-2), 글과 버튼이 어긋난 리뷰는 누구에게 많나 (7-3), 어느 진행 단계에서 실망했나 (7-4), 리뷰를 쓴 뒤에도 계속 플레이했나 (7-5).

플레이시간은 극단값 때문에 중앙값으로 , 추천확률은 0~1 범위의 보정된 확률이라 평균 (= 기대 긍정률) 으로 비교한다 .

종합분석 : 페르소나 x 추천확률 - 1. 누가 만족 / 불만족했나

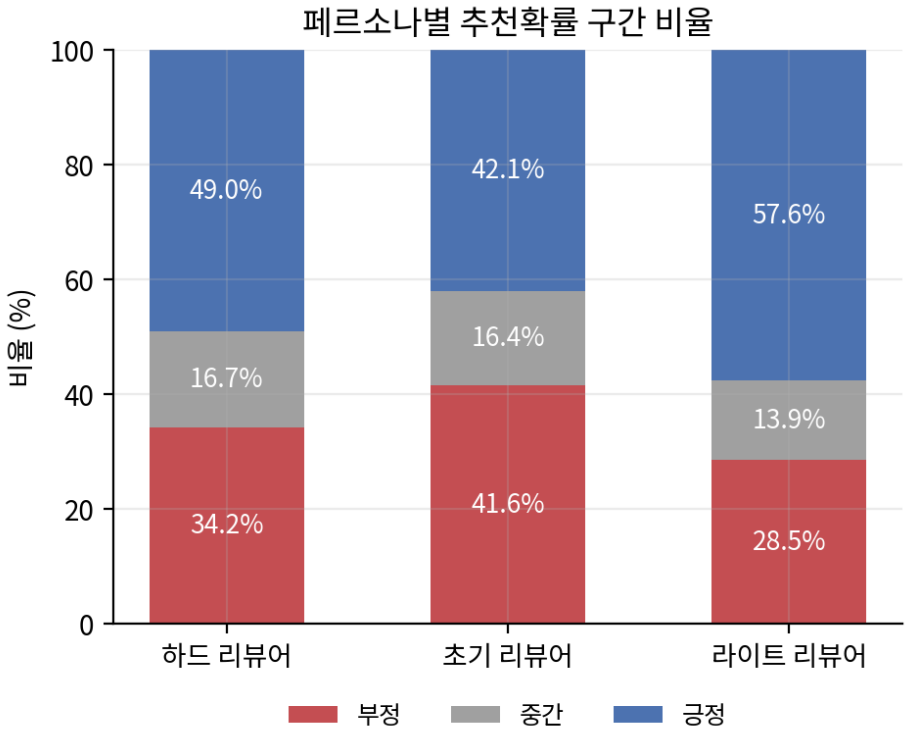


- 라이트 리뷰어 > 하드 리뷰어 > 초기 리뷰어 순으로 추천확률 평균이 높다 (0.64 > 0.57 > 0.51).
  라이트 리뷰어는 하드 리뷰어보다 평균이 0.07 높고 ,
  초기 리뷰어는 하드 리뷰어보다 0.06 낮다

- 평균적으로 라이트 리뷰어 집단이 가장 만족했고 ,
  초기 리뷰어 집단이 가장 불만족했다 .

- 추천확률은 추천 여부를 맞히도록 학습한 점수라
유형별 평균 = 그 집단의 기대 긍정률 (실제 긍정률 0.57 / 0.48 / 0.65 와 거의 일치)
→ 추가로 추천 강도 · 중간 구간 · 불일치를 확인

종합분석 : 페르소나 x 추천확률 - 2. 얼마나 명확하게 평가했나



- 긍정 / 부정 강도를 보기 위해 추천확률을 세 구간으로 구분

  부정 : 0.3 미만

  중간 : 0.3 이상 0.7 미만

  긍정 : 0.7 이상

- 긍정 또는 부정 : 명확하게 긍정 / 부정을 표현한 리뷰

  중간 : 긍정 / 부정이 혼합되어 있거나 애매한 평가를 내린 리뷰

- 라이트 리뷰어 집단이 명확한 긍정 리뷰 비율 (57.6%) 이 가장 높았고 , 모호한 평가 비율이 가장 적게 나타났다 (13.9%).

- 초기 리뷰어 집단이 부정 평가 비율이 가장 높았다 (41.6%).

종합분석 : 페르소나 x 추천확률 - 3-1. 불일치 케이스 분석

[CASE1 불일치 추천 : 추천확률 비추천 구간 & 실제 추천]

快点修复闪退！
(충돌 문제를 최대한 빨리 해결해주세요 !)

Okay Todd, I bought another Skyrim, but this is definitely the last time, I promise you.
(좋아 토드 , 내가 또 다른 스카이림을 사줬지만 이번이 정말 마지막이야 , 진짜로 .)

[CASE2 불일치 비추천 : 추천확률 추천 구간 & 실제 비추천]

Okay what people say is true, game great after a bit.(중략)
Changing to a negative review until bug causing serious issues on linux is fixed.
(그래 사람들이 말한대로 , 조금 하다보니까 게임 완전 재밌어 .(중략) 리눅스에서 심각한 문제를 일으키는 버그가 수정될 때까지 부정적인 리뷰로 전환할거야 .)

- 추천확률의 예측 결과와 실제 추천 여부가 불일치한 케이스를 분석

CASE1(불일치 추천) : 추천확률은 비추천 구간이지만 실제로는 추천을 누른 유저 그룹

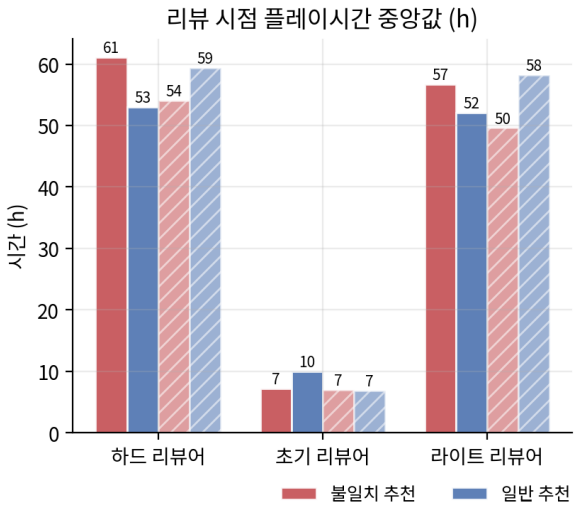
CASE2(불일치 비추천) : 추천확률은 추천 구간이지만 실제로는 비추천을 누른 유저 그룹

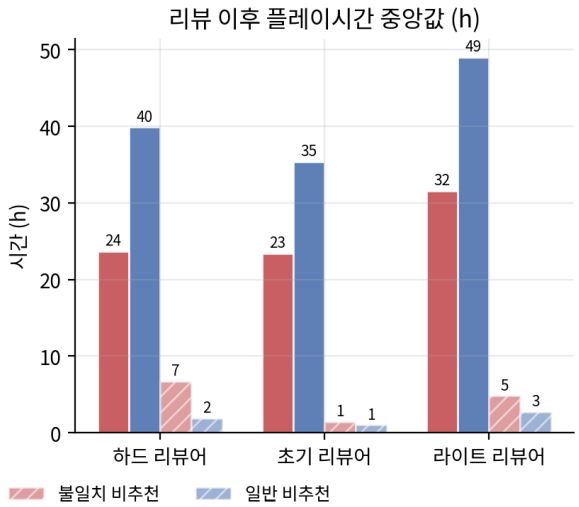
- 두 불일치 그룹의 리뷰 텍스트 샘플을 뽑아 확인

- CASE1 은 불만을 토로하면서 개선을 요구하는 리뷰가 많지만 , 농담 · 반어로 쓴 리뷰도 섞여 있음 (8 장에서 비율 확인)

- CASE2 는 게임의 장점을 칭찬하지만 몇가지 단점때문에 결론은 비추천

종합분석 : 페르소나 x 추천확률 -3-2. 불일치 케이스 분석





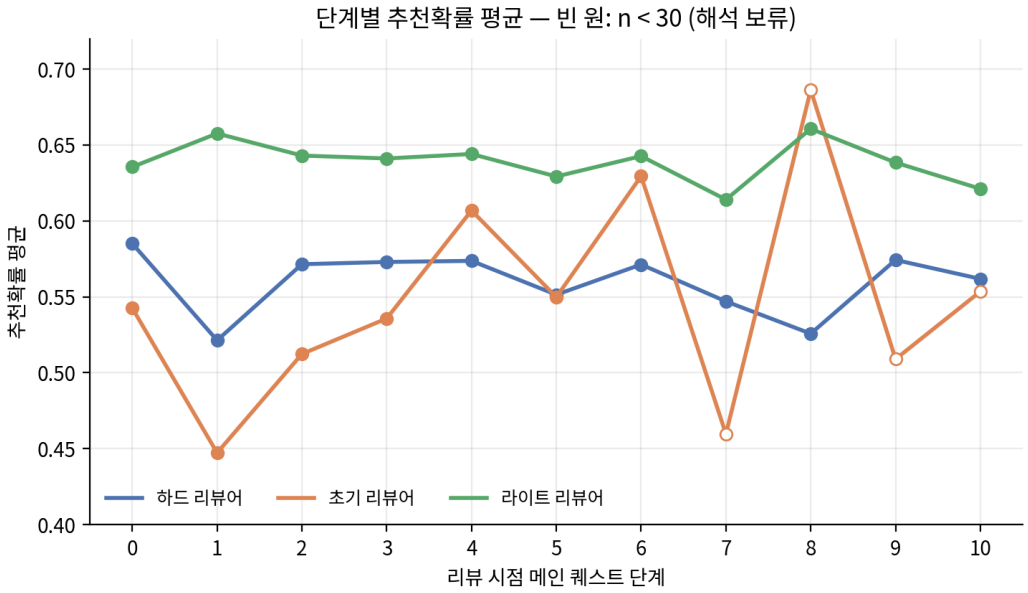
- 불일치 추천 그룹은 일반 추천 그룹
(불일치 추천을 제외한 추천 유저) 에 비해
리뷰 시점 플레이 시간은 더 많고
(초기 리뷰어 그룹은 예외)
리뷰 이후 플레이 시간은 더 적음
→ 더 많이 플레이 해보고 리뷰 작성 했지만
리뷰 이후에는 더 빨리 이탈
(불만사항이 리뷰 이후 플레이시간 감소와 함께 나타남)
- 불일치 비추천 그룹은 일반 비추천 그룹 (불일치 비추천을 제외한 비추천 유저) 에 비해 리뷰 이후 플레이 시간이 더 많음
→ 게임 플레이에 대한 욕구가 아직 남아있음
- 두 불일치 그룹은 불만사항 개선을 통해 플레이 시간 증가를 기대해 볼 수 있음

종합분석 : 페르소나 x 추천확률 - 3-3. 불일치 케이스 분석

그룹이름	부정 · 추천 수	부정 · 추천 비율 (%)	긍정 · 비추천 수	긍정 · 비추천 비율 (%)
하드 리뷰어	734	**2.79**	775	2.95
초기 리뷰어	514	2.47	719	**3.46**
라이트 리뷰어	527	2.21	514	2.16

- 하드 리뷰어 집단에서 부정 · 추천 그룹의 비율이
  가장 높았고 (라이트 리뷰어 대비 +0.58%),
  초기 리뷰어 집단에서 긍정 · 비추천 그룹의 비율이
  가장 높았다 (라이트 리뷰어 대비 +1.3%).

종합분석 : 페르소나 x 추천확률 - 4. 어느 지점에서 실망했나



	0	1	2	3	4	5	6	7	8	9	10
n 하드 리뷰어	295	195	8,836	3,106	2,155	957	1,245	1,154	247	1,043	7,067
n 초기 리뷰어	1,949	3,852	13,933	724	195	74	33	19	1	5	20
n 라이트 리뷰어	259	213	8,017	2,709	1,970	914	1,133	1,165	232	1,135	6,063

- 단계별 평균 추천확률 (= 기대 긍정률) 로 비교 . 0~1 범위라 극단값이 없고 분포가 쌍봉이라 중앙값보다 평균이 안정적 (n < 30 인 점은 빈 원 , 해석 보류)
- 하드 · 초기 리뷰어는 1 단계 리뷰의 평균이 가장 낮음 (하드 0.52, 초기 0.45; 2 단계는 0.57, 0.51) → 게임 초반의 불만 . 8 장에서 그 내용이 성능 · 최적화임을 확인
- 라이트 리뷰어는 단계와 무관하게 0.61~0.66 으로 평탄
- 7 단계는 하드 0.57 → 0.55, 라이트 0.64 → 0.61 로 2~3%p 낮지만 표준오차 (±0.01) 수준이라 뚜렷한 하락으로 보기 어려움
- 초기 리뷰어는 5 단계 이후 리뷰가 74·33·19·1·5·20 건뿐이라 변동이 큼

종합분석 : 페르소나 x 추천확률 - 5. 리뷰 이후엔 어떻게 됐나

그룹이름	유저 수 (명)	중앙값 리뷰 이후 플레이 시간 (h)	유저 잔존 성향 분석
하드 리뷰어	26,300	20.3	전체 통계와 유사한 플레이 패턴을 보임
초기 리뷰어	20,805	9.7	중앙값이 10 시간 미만으로 , 초반 이탈층이 두터움
라이트 리뷰어	23,810	28.9	중앙값 28.9h 로 가장 높은 잔존 성향
전체	70,915	19.7	

추천확률 예측 구간	유저 수 (명)	중앙값 리뷰 이후 플레이 시간 (h)	유저 잔존 성향 분석
부정 (0.3 미만)	24,434	1.7	초고속 이탈 : 그룹 절반이 리뷰 후 1.7 시간 내에 이탈함
중간 (0.3 이상 0.7 미만)	11,106	14.4	완만한 잔존 : 전체 통계보다 조금 적은 시간을 플레이 후 이탈
긍정 (0.7 이상)	35,375	41.3	가장 많은 유저가 속하며 , 리뷰 후에도 40 시간 이상 몰입함

* 플레이시간은 10p 의 상한값 대체 후 값 . 구간 건수는 18p 와 동일 (부정 0.3 미만 / 중간 / 긍정 0.7 이상)

불만 토픽 분석 : 무엇에 실망했나

추천확률 (5 장) 은 리뷰가 얼마나 부정적인지를 재지만 , 무엇이 불만인지는 말하지 않는다 . 7 장은 " 누가 · 얼마나 · 언제 " 실망했는지를 보였고 , 이 장은 그 실망의 이유를 묻는다 .

불만의 내용은 불만이 적힌 글에만 있다 . 그래서 텍스트가 부정인 리뷰 (추천확률 0.3 미만) 를 모아 임베딩 공간에서 군집화하고 , 군집마다 특징어를 뽑아 토픽을 읽는다 .

그 토픽을 7 장의 축 (페르소나 · 진행 단계 · 불일치 케이스) 에 올려 , 유형에 따라 실망의 이유가 다른지 본다 .

불만 토픽 분석 - 1. 분석 대상 선정

어느 리뷰에서 토픽을 뽑을 것인가
후보 네 가지를 비교해 " 텍스트가 부정인 리뷰 전체 " 를 택했다 (우측 표).

분석 대상
· 추천확률 0.3 미만 24,434 건 → 20 자 이상 20,924 건
(비추천 19,537 + 불일치 추천 1,387 · 7 장과 같은 경계)

두 가지 전처리 기준 (근거는 데이터에서 측정)
· 20 자 미만 제외 (3,510 건 , 14.4%): 20 자 미만 리뷰는 "meh", "boring", " 屎 " 처럼 감성만 있고 대상이 없다 . 불만 대상 단어 (최적화 · 로딩 · 모드 · 스토리…) 를 담은 비율이 10~19 자 영어 32%· 중국어 35%, 20 자대 37%·53%. 30 자로 올리면 중국어 불만의 49% 가 빠져 20 자로 정함
· 리뷰 20 건 미만 언어는 'other' 로 묶음 (8 개 언어 57 건 , 0.27%): 언어 보정이 언어별 평균 벡터를 빼는 것이라 1 건뿐인 언어는 자기 자신을 빼 내용이 사라짐 . 언어 평균은 20 건부터 안정 (부분표본 평균과 전체 평균의 코사인 0.9)

후보	판단
리뷰 전체 (70,915)	제외 . 보정해도 군집이 토픽이 아니라 긍정 / 부정으로 먼저 갈리고 , 긍정 군집은 이름을 붙일 수 없었음 (실측)
비추천 버튼 리뷰 (30,373)	제외 . 불일치 추천 (추천 버튼 + 부정 글) 1,775 건이 빠지고 , 텍스트가 부정이 아닌 비추천 7,714 건이 섞임
페르소나 하나	제외 . 세 유형을 비교하는 것이 7 장의 흐름
텍스트 부정 리뷰 전체 (추천확률 < 0.3)	채택 . 7 장의 부정 판정 기준을 그대로 쓰고 , 세 유형 · 모든 단계 · 불일치 추천을 모두 포함 → 7 장 결과 위에 " 이유 " 를 올릴 수 있음

불만 토픽 분석 - 2. 방법 : 임베딩 군집 + c-TF-IDF

① 임베딩 군집 토픽 모델링 — BERTopic 의 3 단계 구조 [6]
· 5 장의 multilingual-e5-large 벡터를 그대로 사용 → K-Means → 군집별 c-TF-IDF 특징어 → 대표 리뷰를 읽고 사람이 이름 부여
· k = 10: 실루엣이 k 4~15 전 구간에서 0.04 로 평평 (같은 게임의 불만은 경계 없는 연속체) → 해석 가능성으로 선택 . k = 7·13 에서도 결론 유지

② 함정 — 보정 없이 군집화하면 토픽이 아니라 언어와 길이로 갈린다
· 임베딩은 " 무슨 말 " 뿐 아니라 " 어느 언어로 , 얼마나 길게 " 도 담는다 . 같은 게임 리뷰끼리는 후자의 차이가 더 커서 중국어 군집 · 긴 영어 군집이 먼저 생김
· 언어 더미 + log(길이) 를 임베딩에 회귀하고 잔차만 사용 = 언어별 평균 벡터와 공통 길이 성분을 뺌 ([7] 언어별 중심화 , [8] 회귀 잔차 = 선형 제거의 최적해)
· 검증 : 보정 후 벡터로 언어 맞히기 0.96 → 0.75 = 최빈 언어만 찍는 수준 . 성능 군집에 중국어 · 러시아어 · 터키어 리뷰가 같은 불만으로 모임

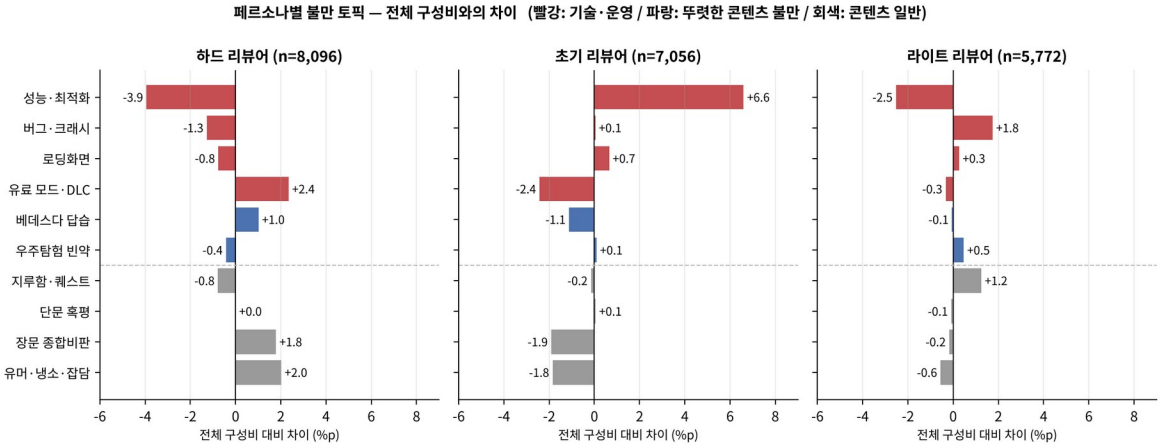
단계	내용
① 대상	텍스트 부정 리뷰 20,924 건의 e5 벡터 (1,024 차원)
② 보정	언어 더미 + log(길이) 회귀 잔차 → 단위벡터
③ 군집	K-Means k = 10 (시드 3217, n_init 10)
④ 토픽어	영어 리뷰 c-TF-IDF 상위어 + 대표 리뷰 → 이름

불만 토픽 분석 - 3. 불만 토픽 10 개

구분	토픽	n (구성비)	리뷰 시점 플레이 중앙값	불일치 추천 비율	특징어 (c-TF-IDF)	대표 리뷰
기술 · 운영	성능 · 최적화	1,553 (7.4%)	9.9h	8.4%	pc, performance, fps, dlss, settings	Game becomes unplayable on PC, non stop stuttering
기술 · 운영	버그 · 크래시	1,495 (7.1%)	39.6h	8.6%	bugs, fix, save, crashes	Save file has been corrupted after 45 hours of playing
기술 · 운영	로딩화면	1,250 (6.0%)	31.2h	4.6%	loading screens, simulator, travel	30 hours of "gameplay" + 10 hours of loading screens
기술 · 운영	유료 모드 ·DLC	1,475 (7.0%)	61.5h	4.9%	mods, paid mods, modders, creation	The new push for paid mods ended it all
콘텐츠 (뚜렷)	베데스다 답습	3,026 (14.5%)	39.2h	4.0%	fallout, skyrim, bethesda game, elder scrolls	It's all the worst parts of Skyrim with none of what made that game great
콘텐츠 (뚜렷)	우주탐험 빈약	2,820 (13.5%)	34.4h	5.8%	space, planets, travel, exploration	Vast as an ocean, deep as a puddle
콘텐츠 일반	지루함 · 퀘스트	2,648 (12.7%)	36.9h	6.5%	boring, hours, story, quests	The quests are boring… you spend most of the time looking at maps
콘텐츠 일반	단문 혹평	1,906 (9.1%)	35.1h	5.1%	(중앙 79 자) ship, space, bad	Absolutely no innovation whatsoever. Boring everything
콘텐츠 일반	장문 종합비판	1,603 (7.7%)	47.0h	5.6%	(중앙 616 자) fallout, skyrim, story	I really tried to like Starfield, I really did, but I just can't anymore
콘텐츠 일반	유머 · 냉소 · 잡담	3,148 (15.0%)	42.8h	11.3%	공통어뿐 (ship, space, time)	We can't pet DOGY so you can't be GOTY

· 기술 · 운영 4 개와 콘텐츠 2 개는 특징어로 바로 읽히는 뚜렷한 토픽 . 콘텐츠 일반 4 개는 " 무엇 " 이 아니라 " 형식 "(길이 · 어조) 으로 갈린 군집이라 한 묶음으로 읽는다
· 불일치 추천 비율 = 그 토픽 안에서 추천 버튼을 누른 리뷰의 비율 . 유머 · 냉소 · 잡담이 11% 로 유독 높다 (8-5)

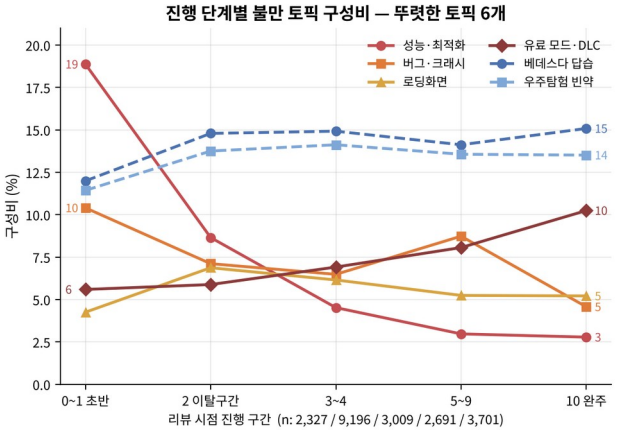
불만 토픽 분석 - 4. 누가 무엇에 실망했나 (페르소나 × 토픽)

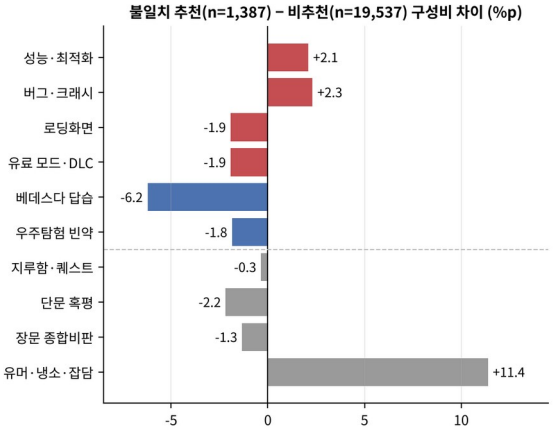


- 콘텐츠 불만 (파랑 · 회색) 은 세 유형에서 비중 차이가 ±2%p 안 : " 우주가 비었다 , 지루하다 , 전작 답습이다 " 는 누가 쓰든 같은 비중
- 차이는 기술 · 운영 불만 (빨강) 에서 난다
  · 초기 리뷰어 : 성능 · 최적화 14.0% (전체 7.4% 의 두 배)
  · 하드 리뷰어 : 유료 모드 ·DLC 9.4% (초기 4.6%), 장문 종합비판 9.4%
  · 라이트 리뷰어 : 버그 · 크래시 8.9% (하드 5.9%)
- 초기 리뷰어의 성능 불만은 " 일찍 써서 " 만이 아니다 : 같은 2 단계 리뷰 안에서도 초기 11.6% vs 하드 4.9% · 라이트 6.4%
- χ^2 $p < 0.001$, Cramér's V 0.15 → 연관은 약하고 , 기술 · 운영 토픽에 국소적으로 집중

* n = 하드 8,096 · 초기 7,056 · 라이트 5,772 (텍스트 부정 리뷰 20 자 이상). 막대 = 유형별 구성비 − 전체 구성비 (%p)

불만 토픽 분석 - 5. 언제 무엇에 , 그리고 불일치 추천은 무엇을 쓰나





진행 단계별

· 성능 · 최적화는 0~1 단계 19% → 완주 3% 로 사라지고 , 유료 모드 ·DLC(6 → 10%) 와 장문 종합비판 (5 → 9%) 이 는다 → 초반 불만은 기술 , 후반 불만은 운영 · 총평

· 7 단계 부정 리뷰의 토픽 구성은 5·6·8·9 단계와 ±3%p 안 → 초반 (0~1 단계) 을 빼면 단계별 불만 구성은 안정적

불일치 추천 (추천 버튼 + 부정 글) vs 비추천

· 유머 · 냉소 · 잡담이 25.7% vs 14.3% 로 가장 크게 는다 : "I love the game and absolutely despise the inventory system", " 개를 못 쓰다듬으니 GOTY 못 됨 " 같은 조건부 불만과 농담 · 반어를 분류기가 부정으로 읽은 것

· 이를 걷어내면 성능 · 버그 등 기술 불만이 비추천보다 2%p 씩 높고 베데스다 답습은 6%p 낮다 → 7-3 의 " 개선 요구 " 는 이 기술 불만 부분을 근거로 읽어야 한다

결론과 한계 - 1. 네 질문에 대한 답

Q1. 리뷰 텍스트만으로 평가를 예측할 수 있는가 → 있다
· 다국어 임베딩 + 로지스틱 회귀 , 5-fold out-of-fold AUC 0.954 · 정확도 0.887
· 예측확률이 구간별 실제 추천 비율과 일치 → 연속 점수 " 추천확률 " 로 사용 . 세 유형 모두 AUC 0.948~0.963

Q2. 플레이 행동으로 리뷰어를 나눌 수 있는가 → 세 유형
· 초기 리뷰어 29%(플레이 8h · 업적 3 개 시점), 하드 리뷰어 37% (보유 게임 431 · 리뷰 29 편 · 55h), 라이트 리뷰어 34%(보유 게임 124 · 리뷰 5 편 · 54h)
· 실루엣은 k=2(0.279) 가 높지만 플레이시간 축으로만 갈려 게임 경험 축이 사라짐 → k=3

Q3. 유형에 따라 평가가 어떻게 다른가 → 우측 표
· 누가 · 얼마나 · 언제 · 그 뒤가 모두 다르다

Q4. 유형과 단계에 따라 " 무엇에 " 실망하는가 → 기술 · 운영 불만에서 갈린다
· 텍스트 부정 리뷰 20,924 건 → 토픽 10 개 (기술 · 운영 4 + 콘텐츠 6). 콘텐츠 불만 (72%) 은 유형과 무관하고 , 초기 = 성능 (2 배) · 하드 = 유료 모드 · 라이트 = 버그 . 성능 불만은 초반 19% → 완주 3%

질문	결과
누가	추천확률 평균 라이트 0.64 > 하드 0.57 > 초기 0.51 (초기는 하드보다 0.06 낮음). 초기 리뷰어는 리뷰의 42% 가 명확한 부정 (0.3 미만), 라이트는 58% 가 명확한 긍정
얼마나	불일치 추천 (텍스트 부정 · 실제 추천) 은 하드 리뷰어에 가장 많고 (2.8%, 라이트 대비 +0.6%p), 불일치 비추천 (텍스트 긍정 · 실제 비추천) 은 초기 리뷰어에 가장 많다 (3.5%, +1.3%p). 불일치 추천은 일반 추천보다 리뷰 후 플레이가 짧고 , 불일치 비추천은 일반 비추천보다 길다
언제	하드 · 초기 리뷰어는 1 단계 리뷰의 평균이 가장 낮음 (0.52 / 0.45). 라이트는 단계와 무관하게 평탄 . 7 단계의 공통 하락은 2~3%p 로 뚜렷하지 않음
그 뒤	추천확률 0.3 미만 리뷰어의 절반은 리뷰 후 1.7 시간 안에 그만둠 , 0.7 이상은 41 시간 더 플레이 . 초기 리뷰어 리뷰 후 플레이 중앙값 9.7h vs 라이트 28.9h
무엇에	초기 리뷰어는 성능 · 최적화 (14% vs 전체 7%), 하드는 유료 모드 ·DLC(9%), 라이트는 버그 · 크래시 (9%). 콘텐츠 불만은 유형과 무관 . 불일치 추천의 1/4 은 농담 · 반어

결론과 한계 - 2. 가설 판정과 시사점

가설	판정	근거
H1. 게임 경험이 많은 유형일수록 비판적일 것이다	조건부 지지	플레이시간이 비슷한 하드 (55h) 와 라이트 (54h) 를 비교하면 경험 많은 하드 쪽이 더 비판적 (긍정률 57% vs 65%). 단 , 가장 비판적인 집단은 경험이 아니라 리뷰 시점이 이른 초기 리뷰어
H2. 플레이시간이 짧은 시점에 쓴 리뷰일수록 부정적일 것이다	지지	초기 리뷰어 긍정률 48% 로 최저 . 하드 · 초기 리뷰어에서는 1 단계 리뷰의 추천확률이 가장 낮음 (라이트 리뷰어는 단계와 무관)

시사점 — 무엇을 먼저 고쳐야 하나

· 가장 부정적인 집단 (초기 리뷰어) 은 8 시간 ·2 단계 이하에서 리뷰를 쓰고 , 그중 절반은 10 시간 안에 그만둔다 . 그 불만의 핵심은 성능 · 최적화 (14%, 다른 유형의 3~4 배) → 초반 최적화가 평가와 잔존을 함께 결정

· 불일치 비추천 (텍스트 긍정 · 실제 비추천) 은 초기 리뷰어에 가장 많다 (3.5%). 그리고 전체적으로 일반 비추천자보다 리뷰 후 플레이가 길어 플레이 욕구가 남아 있는 집단 → 초반 불만을 고치면 되돌릴 여지가 가장 큰 1 차 대상

· 불일치 추천 (텍스트 부정 · 실제 추천) 의 리뷰는 개선 요구의 1 차 자료 — 단 , 4 분의 1 은 농담 · 반어 (8 장) 라 걸러 읽어야 하며 , 걸러낸 뒤에는 버그 · 성능 불만이 비추천보다 높다 . 더 많이 플레이한 뒤 추천을 유지한 채 불만을 쓰고 리뷰 후에는 빨리 떠난다 → 개선 시 플레이시간 증가를 기대

결론과 한계 - 3. 한계와 후속 과제

한계

· 모집단 : 업적이 공개된 리뷰어 72,271 명 (전체 리뷰 175,300 건의 41%). 비공개 유저와 리뷰를 쓰지 않은 유저는 보지 못함 . 제외한 업적 0 개 999 명 중 458 명은 5 시간 미만에 그만둔 조기 이탈자로 추정 (긍정률 23%) — 포함했다면 초기 리뷰어의 부정 성향은 더 강하게 나왔을 것

· 언어별 성능 격차 (AUC 한국어 0.86 ~ 헝가리어 0.98). 길이를 통제해도 남는 모델 자체의 격차라 한국어 결과는 이 오차를 감안 . language 는 클라이언트 설정값이라 실제 글의 언어와 다를 수 있음

· 불만 토픽 (8 장): 콘텐츠 군집 6 개는 경계 없는 연속체라 이름이 근사치 (실루엣 0.04). 언어 성분은 선형으로만 제거해 비선형 잔존 가능 . 불일치 추천 1,387 건은 다른 임베딩 모델로 재현을 확인하지 못함

· 관찰 데이터의 상관이지 인과가 아님 . 리뷰 시점 값과 수집 시점 (2026-09) 값이 섞여 있어 리뷰 후 플레이시간에는 최대 3 년의 관측 창 차이가 포함됨

· 불일치 추천 · 비추천은 분류기 기준의 오분류이기도 하다 . 짧은 글 (22% vs 14%) 과 농담 · 반어 토픽 (26% vs 14%) 이 많아 일부는 모델 한계이며 , 진짜 불일치와 구분하려면 수작업 검증이 필요하다 . 다만 리뷰 후 플레이가 일반 추천보다 짧다는 행동 차이는 오분류만으로는 설명되지 않는다

후속 과제

· 7 단계 공통 하락 (2~3%p) 이 실제인지 — 플레이 로그 · 패치 시점과 함께 확인

· 한국어권 : 유형을 통제해도 추천확률 평균이 − 5~−19%p 낮다 . 부정 리뷰 164 건뿐이라 토픽 분석이 어려워 원인 (현지화 · 가격) 은 후속

· 출시 후 경과 시점 (2023-09 → 2026-09) 별 추세 : 성능 불만이 패치 이후 줄었는지 , 유료 모드 불만이 언제 생겼는지 , DLC 전후 비교

· 제외한 조기 이탈 458 명을 포함한 민감도 분석

참고문헌

[1] Enhancing churn forecasting with sentiment analysis of Steam reviews. Social Network Analysis and Mining (2024). https://link.springer.com/article/10.1007/s13278-024-01337-3
[2] Length and sentiment analysis of reviews about top-level video game genres on the Steam platform. Computers in Human Behavior (2023). https://doi.org/10.1016/j.chb.2023.107955
[3] Unravelling Player's Insights: A Comparative Analysis of Topic Modelling Techniques on Game Reviews. IEEE Transactions on Games (2024).
[4] Muennighoff, N. et al. (2023). MTEB: Massive Text Embedding Benchmark. EACL. https://aclanthology.org/2023.eacl-main.148/
[5] Xiao, C. et al. (2023). Length is a Curse and a Blessing for Document-level Semantics. EMNLP. https://aclanthology.org/2023.emnlp-main.86/
[6] Grootendorst, M. (2022). BERTopic: Neural topic modeling with a class-based TF-IDF procedure. arXiv:2203.05794.
[7] Libovický, J., Rosa, R. & Fraser, A. (2020). On the Language Neutrality of Pre-trained Multilingual Representations. Findings of EMNLP. https://aclanthology.org/2020.findings-emnlp.150/
[8] Belrose, N. et al. (2023). LEACE: Perfect linear concept erasure in closed form. NeurIPS. arXiv:2306.03819.

데이터 · 모델

· Steam Store appreviews API (https://store.steampowered.com/appreviews/1716740?json=1), Steam Web API GetPlayerAchievements — 수집 2026-09-08
· intfloat/multilingual-e5-large (Wang et al., 2024, arXiv:2402.05672) · Qwen/Qwen3-Embedding-0.6B (비교용)

부록 — 데이터셋 미사용 열

부록 1. 리뷰에 대한 타인의 반응 — 분석 미사용

열 이름	타입	내용	값 범위 · 주의	사용
votes_up	int	“ 유용함” 투표 수	최대 15,871 / 46.6% 가 0.	–
votes_funny	int	“ 재미있음” 투표 수	최대 3,456 / 82.5% 가 0	–
weighted_vote_score	float	Steam 자체의 유용성 점수	0.004~0.971. 49.5% 가 0.5 = 기본값	–
comment_count	int	댓글 수	최대 625, 96.5% 가 0	–
reactions	str(list)	이모지 반응	89.2% 가 빈 리스트 . 문자열로 저장됨	–
timestamp_dev_responded	float	개발사 답변 시각	1,355 건 (1.9%) 만 . 2023-09-19 ~ 11-28	–
developer_response	str	개발사 답변 본문	위와 동일 건 . 정형 문구	–

부록 — 데이터셋 미사용 열

부록 2. 구매 · 플랫폼 플래그 — 분석 미사용

열 이름	타입	내용	값 범위 · 주의	사용
steam_purchase	bool	Steam 에서 직접 구매	True 57.0%	–
received_for_free	bool	무료로 받음	True 2.7%	–
refunded	bool	환불 여부	True 41 건	–
primarily_steam_deck	bool	주로 Steam Deck 으로 플레이	True 0.7%	–
deck_playtime_at_review	float	리뷰 시점 Deck 플레이 시간	96.2% 결측	–